

解 説

EM アルゴリズムの原理と応用

田中 雅博*

1. はじめに

EM アルゴリズムは Expectation-Maximization algorithm の略で、20 年前に Dempster, Laird, Rubin⁶⁾により定式化され命名された最尤推定法のためのアルゴリズムである。特に欠測データを含む問題に対する方法と認識されているが、表に出ない確率変数を仮想的に置くことにより尤度関数の扱いが簡単になるような場合に、その仮想的に置く変数を「欠測値」と呼ぶのであって、普通の意味での欠測値だけではないことを知っておくことは重要である。事実、EM アルゴリズムと同じ発想のアルゴリズムが、Dempster らの論文が発表されるずっと前に Hartley⁸⁾により、離散分布の最尤推定を行う際に、いくつかのデータが集約 (aggregated) データであった場合に用いられたようである。

Dempster らの論文にはイニシャルをとった DLR という愛称が与えられ、EM アルゴリズムといえば必ず引用される。もともと EM アルゴリズムは純粋に統計学の分野の研究であるので、統計の問題に限定はされるが、DLR の中ですでに多くの応用問題を示唆している。例を挙げると、欠測データ、多項分布において部分的に集約データしか得られないケース、群別化 (grouping)、中途打ち切り (censoring)、切断 (truncation)、状態が有限個あって、観測がそのいずれかから発生しているが発生源が特定されていないケース (finite mixture)、同定したいパラメータと観測値の間にもう一段パラメータがあるような問題 (hyperparameter estimation)、因子分析 (factor analysis) などである。これらは、EM アルゴリズムの応用問題として、古くから着目されていたことに注目したい。

EM アルゴリズムに関しては、理論的な面からの解説は優れたものがすでにくつも発表されている。宮川¹⁸⁾は、統計学から見た EM アルゴリズムを非常に詳しく述べている。とくに、Dempster らにより定式化される前の

応用を紹介している点が興味深い。甘利の数々の論文や解説 (例えば参考文献 2), 3)) では情報幾何学という立場から EM アルゴリズムを説明しており、この分野に興味のある読者には大変刺激的であろう。赤穂¹⁾は、甘利らの幾何学からの解釈をわかりやすく論じている。Moon¹⁹⁾は初心者向けの EM アルゴリズム全般の解説である。

本解説は、近年見かけることの多い、EM アルゴリズムという名前へ興味を持ち、応用分野で使おうとしている比較的経験の浅い読者に、具体的方法を丁寧に述べることで、理解の助けにすることを目的としている。

最近、統計学、データベース論および機械学習を統合した分野でデータマイニング⁷⁾という名前が使われているが、ここでも多くの問題に EM アルゴリズムがすでに使われていたり、潜在的な利用可能分野であることは注目に値する。EM アルゴリズムは、最尤推定の一つの解法であると同時に、主成分分析をはじめとする多変量解析の新しい解法を与えたり、ニューラルネットの学習方法を与えるものとして、広い分野での応用の可能性を持っているといえよう。

2. EM アルゴリズム

2.1 アルゴリズムの定義

いま対象としている問題に対して当てはめる確率分布の関数形を決め、その中のパラメータをデータから決めたいものとする。未知パラメータをまとめて集合 Θ として表現しよう。たとえば、ガウス分布でいうと、 $\Theta = \{\mu, \sigma^2\}$ である。 Θ の各要素を与えたときに、得られている観測値 y が出現する確率 $P(y|\Theta)$ (または確率密度関数 $f(y|\Theta)$) を最大にするようなパラメータ Θ を求める方法を最尤推定法 (maximum likelihood estimate) という。尤度関数は $f(y|\Theta)$ の対数をとって

$$L(\Theta) = \log f(y|\Theta) \quad (1)$$

とすることも多い。

最尤推定法における最適パラメータは尤度関数の形が特殊な場合は直ちに求まることもあるが、通常は勾配や

* 岡山大学 工学部

Key Words: EM algorithm, missing data, statistical modeling.

ヘッセ行列などを用いた最適化手法により繰り返し計算をして解を求める必要がある。しかしながら、分布モデルを簡単に表現できるようにするために中間変数 x を架空に設けることにより、たいへん楽にパラメータの推定ができることがある。ちなみに、観測値 y は x が何らかの観測機構の制約から冒頭に挙げたような理由で不完全な形で観測されたものとする。例えば2次元でいうと x_1, x_2 の両方がわかったら簡単に最尤推定できるような場合に、集約の場合なら、 $y = x_1 + x_2$ 、欠測の場合には $y = x_2$ しか観測されないということに該当する。EM アルゴリズムでは、 x は完全データ (complete data)、通常の観測値 y は不完全データ (incomplete data) と呼び、尤度関数 (ここでは不完全尤度ともいう) $f(y|\theta)$ を直接最大化するかわりに完全尤度 $f(x|\theta)$ を使って間接的に $f(y|\theta)$ の最大化を図る。期待ステップ (E ステップ) と最大化ステップ (M ステップ) からなるそのアルゴリズムを次に定義しよう。

まず観測値 y と現在利用できるパラメータの一時的な値 α に基づいた条件付き期待値

$$Q(\theta|\alpha) = E[\log f(x|\theta)|y, \alpha] \quad (2)$$

$$= \int \log f(x|\theta) f(x|y, \alpha) dx \quad (3)$$

を導入する。ここで、あらゆる $\theta \in \Omega$ (Ω はパラメータ空間) について $f(x|\theta) > 0$ と仮定する。

【定義 1】 (EM アルゴリズム)

パラメータ初期値 $\theta^{(0)}$ を与え、次の E ステップと M ステップを $p=0, 1, \dots$ について繰り返す。

E ステップ $Q(\theta|\theta^{(p)})$ を計算する。

M ステップ $Q(\theta|\theta^{(p)})$ を最大化する $\theta \in \Omega$ を $\theta^{(p+1)}$ とする。

欠測値がなくすべてが観測できる場合には E ステップが不要となり、M ステップは $Q(\theta|\alpha) = \log f(y|\theta)$ のによる最大化となり、通常の最尤推定法に帰着する。

上記 EM アルゴリズムをそのまま実行しようとする、E ステップの条件付き期待値の計算が困難な場合が多い。場合によっては、すべての θ について期待値を数値計算で求める必要が生じる。この場合は、EM アルゴリズムを導入する意味が少ない。しかしながら、 $f(x|\theta)$ が指数型分布族 (exponential family of distributions) である場合、つまり

$$f(x|\theta) = \frac{b(x) \exp(c^T(\theta)t(x))}{a(\theta)} \quad (4)$$

(上付きの T は転置を示す) のような形に書ける分布の場合には、E ステップが簡単化される。ここに、 $t(x)$ は十分統計量である。指数型分布族に対する EM アルゴリ

ズムを導いておこう。

まず E ステップでは

$$Q(\theta|\theta^{(p)}) = E[\log b(x)|y, \theta^{(p)}] + c(\theta)^T E[t(x)|y, \theta^{(p)}] - \log a(\theta^{(p)}) \quad (5)$$

となる。次の M ステップでは $E[\log b(x)|y, \theta^{(p)}]$ は不要であるからこの期待値を計算する必要はなく、結局

E ステップ

$$\hat{t}(x) = E[t(x)|y, \theta^{(p)}]$$

M ステップ

$$\theta^{(p+1)} = \arg \max_{\theta} \{c^T(\theta)\hat{t}(x) - \log a(\theta^{(p)})\}$$

を計算することになる。

ちなみに、指数型分布族に属する分布としては、ガウス分布、指数分布、2 項分布、ポアソン分布などがある。ガウス分布 $f(x|\theta) = N(m, \sigma^2)$ は $\theta = \{m, \sigma^2\}$ であり

$$c(\theta) = \left[m \quad -\frac{1}{2\sigma^2} \right]^T \quad (6)$$

$$t(x) = [x \quad x^2]^T \quad (7)$$

$$a(\theta) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{m^2}{2\sigma^2}\right) \quad (8)$$

$$b(x) = 1 \quad (9)$$

である。なお、ここでは指数分布族の特徴を強調するために上のような変形を行ったが、EM アルゴリズムを導入際には上のような形の変形をいつも行う必要はない。

ここで、M ステップで $Q(\theta|\theta^{(p)})$ を最大化するのが困難なときにも EM アルゴリズムと類似の計算が有効であることを示す。

パラメータ θ の更新をアルゴリズム M で行うことを

$$\theta^{(p+1)} = M(\theta^{(p)}) \quad (10)$$

と表現してみよう。この表現を用いて、次の一般化 EM (GEM) アルゴリズム⁶⁾ (Generalized EM algorithm) を定義する。

【定義 2】 (GEM アルゴリズム)

$$Q(M(\theta)|\theta) \geq Q(\theta|\theta) \quad (11)$$

が任意の $\theta \in \Omega$ について成り立つものを GEM アルゴリズムという。

ここでいう一般化とは、M ステップにおいて、必ずしも最大化を行わないという意味である。 $\theta^{(p)}$ が最適でなければそれよりも $Q(\theta|\theta^{(p)})$ を大きくする θ が存在する。

2.2 収束性

GEM アルゴリズムについて次の定理が成り立つことが証明されている⁶⁾。

【定理 1】 (GEM の性質)

任意の GEM アルゴリズムについて

$$L(M(\theta)) \geq L(\theta) \quad (12)$$

がすべての θ について成り立つ。ここで

$$L(\theta) = \log f(y|\theta) \quad (13)$$

である。

(略証)

y とそれに対応する完全データ x について考えているので

$$f(x|y, \theta) = \frac{f(y|x, \theta)f(x|\theta)}{f(y|\theta)} = \frac{f(x|\theta)}{f(y|\theta)} \quad (14)$$

が任意の θ について成り立つ。よって

$$L(\theta) = \log f(x|\theta) - \log f(x|y, \theta) \quad (15)$$

となる。両辺の条件付き期待値をとると

$$E[L(\theta)|y, \alpha] = E[\log f(x|\theta)|y, \alpha] - E[\log f(x|y, \theta)|y, \alpha] \quad (16)$$

となる。不完全尤度 $L(\theta)$ は y の関数ではあるが y は条件で与えられているので (16) 式の更新に伴う変化の条件付き期待値について

$$E[L(\theta)|y, \theta] = L(\theta) \quad (17)$$

$$E[L(M(\theta))|y, \theta] = L(M(\theta)) \quad (18)$$

が成り立つ。ここで尤度関数値の変化分を求めるに際し、(15) 式に着目すると、まず条件より

$$E[\log f(x|M(\theta))|y, \theta] - E[\log f(x|\theta)|y, \theta] \geq 0 \quad (19)$$

が成り立つ。次に右辺第 2 項目に関しては、参考文献 22) の (1e.6.6) 式 (詳しい証明はそこに与えられている) より直ちに得られる

$$E[\log f(x|y, M(\theta))|y, \theta] \leq E[\log f(x|y, \theta)|y, \theta] \quad (20)$$

が任意の θ について成り立つことより (12) 式が証明される。□

よって、EM アルゴリズムを含む GEM アルゴリズムでは普通の意味での尤度関数、すなわち不完全尤度が減少することではなく、さらに、緩い条件のもとで局所解に収束することが示されている³⁵⁾。大域的最適解が得られる保証はないが、パラメータの更新式 $\theta^{(p+1)} = M(\theta^{(p)})$ より、一次収束するということはすぐにわかる。また、Xu ら³⁶⁾は、EM アルゴリズムはガウス混合分布の同定の場合について、超一次収束をする、すなわち、 $\theta^* = M(\theta^*)$ とするときある $1 < r < 2$ に対し

$$\|\theta^{(p+1)} - \theta^*\| \leq q \|\theta^{(p)} - \theta^*\|^r \quad (21)$$

を満たす、 p に独立な定数 q が存在するということを示している。しかしながら、EM アルゴリズムの特徴は速度よりも使いやすさ、すなわち、一次元探索や学習係数の設定などを必要とせず、制約式も自動的に満たす、といった点にある。

3. いくつかの応用例

ここでは、いくつかの問題における適用方法を紹介しよう。

3.1 多次元ガウス混合密度関数

多変数ガウス密度関数を用いた確率モデルは、多属性データの分布を簡潔に表現する方法としてたいへん有用であり、パターン認識やデータマイニングのさまざまな問題に適用可能である。

y を n 次元ベクトルとし、ガウス混合密度関数

$$f(y) = \sum_{i=1}^G \pi_i f_i(y) \quad (22)$$

を構成するガウス関数を


$$f_i(y) = N(y|m_i, \Sigma_i) = \frac{\exp\left(-\frac{1}{2}(y-m_i)^T \Sigma_i^{-1}(y-m_i)\right)}{(2\pi)^{n/2} |\Sigma_i|^{1/2}} \quad (23)$$

とする[†]。ここで Σ_i は正定値対称行列であり、絶対値記号は行列式を表す。このガウス関数混合密度関数には、 G 組の未知パラメータ $\{\pi_i, m_i, \Sigma_i\}$ $i=1, \dots, G$ が含まれている。ただし $\sum_i \pi_i = 1$ である。ガウス混合密度関数は指数型分布族ではないが、各データ $y(k)$ がいずれのガウス分布から生成されたものであるかを示す選択変数 $s(k) \in \{1, \dots, G\}$ を導入することで指数型分布族となる。ちなみに、 $s(k)=i$ の事前確率を $\pi_i (i=1, \dots, G)$ とおいている。

ガウス混合密度データの生成原理を第 1 図に示す。

完全尤度関数は $\{(s(k), y(k)), k=1, \dots, N\}$ の同時確

[†] 下付きの添え字はすべてガウス関数の番号を示しており、ベクトルの要素番号ではないので注意されたい。また、 Σ_i は $\sum_i$ ではないので、これにも注意をお願いしたい。



第 1 図 ガウス混合モデル

率密度関数であるが、 $s(k)$ は離散値しかとらないので厳密には定義できない。しかしながら、多くの場合なされているように、 $f(s, y) = f(y|s)P(s)$ と定義することにより完全尤度関数が定義でき、EM アルゴリズムが導ける。独立に観測されたデータが全部で N 組あるとき $L(\Theta) = f((s(k), y(k)), k=1, \dots, N|\Theta)$ とおくと

$$L(\Theta) = \prod_{k=1}^N \pi_i f_i(y(k)) \Big|_{i=s(k)} \quad (24)$$

となる。E ステップは観測値に基づいて、未知変数の条件付き期待値より求められ、M ステップは各未知パラメータで偏微分して 0 とおくことにより得られる尤度方程式より得られる。今後表記の簡単化のために古いパラメータを Θ , 更新された新しいパラメータを $\tilde{\Theta}$ と記する。詳細は参考文献 36), 27), 24) などに記載されているので、参照されたい。

E ステップ

$$\begin{aligned} \bar{w}_i(y(k)) &= P(s(k)=i|y(k), \bar{\Theta}) \\ &= \frac{\bar{\pi}_i N(y(k)|\bar{m}_i, \bar{\Sigma}_i)}{\sum_{j=1}^G \bar{\pi}_j N(y(k)|\bar{m}_j, \bar{\Sigma}_j)} \end{aligned} \quad (25)$$

M ステップ

$$\tilde{\pi}_i = \frac{1}{N} \sum_{k=1}^N \bar{w}_i(y(k)) \quad (26)$$

$$\tilde{m}_i = \frac{\sum_{k=1}^N \bar{w}_i(y(k)) y(k)}{\sum_{k=1}^N \bar{w}_i(y(k))} \quad (27)$$

$$\tilde{\Sigma}_i = \frac{\sum_{k=1}^N \bar{w}_i(y(k)) (y(k) - \tilde{m}_i)(y(k) - \tilde{m}_i)^T}{\sum_{k=1}^N \bar{w}_i(y(k))} \quad (28)$$

さらに、Tanaka³⁰⁾は、ガウス混合モデルにおいて、観測が欠ける問題を扱っている。なお、データのランクがフ

ルランクでない場合、あるいはいずれかのガウス関数で共分散行列が縮退するような場合については、ここで示したアルゴリズムをそのまま用いることはできず、モデルにひと工夫必要である。また、使用するガウス関数の個数については、ニューラルネットの隠れユニット数の決定同様、難しい問題である。

本アルゴリズムは、局所探索アルゴリズムであるから、初期値により結果が大きく異なる可能性もある。初期値の決め方に関しては、遺伝的アルゴリズムその他、何らかの大域的最適化を志向したアルゴリズムを用いることが考えられる。

【例題 1】 ここで、一つ計算例を示しておこう。 $G=2$ とし、 $N=500$ 個のデータを

$$\pi_1 = 0.7, N \left(\begin{bmatrix} -1 \\ -2 \end{bmatrix}, \begin{bmatrix} 1 & 0 \\ 0 & 4 \end{bmatrix} \right)$$

$$\pi_2 = 0.3, N \left(\begin{bmatrix} 2 \\ 1 \end{bmatrix}, \begin{bmatrix} 5 & 0 \\ 0 & 1 \end{bmatrix} \right)$$

で生成した。これに対し、 G はそのまま 2 として、 m_1, m_2 の初期値はランダムに選んだ 2 点のデータの値とし、共分散行列は単位行列、 $\pi_1^{(0)} = \pi_2^{(0)} = 0.5$ として EM アルゴリズムを実行した。40 回繰り返した後のパラメータは次のようになった。

$$\pi = 0.717, N \left(\begin{bmatrix} -0.999 \\ -1.977 \end{bmatrix}, \begin{bmatrix} 1.0290 & -0.0791 \\ -0.0791 & 3.9846 \end{bmatrix} \right)$$


$$1 - \pi = 0.283, N \left(\begin{bmatrix} 1.8003 \\ 0.9653 \end{bmatrix}, \begin{bmatrix} 4.8926 & 0.0426 \\ 0.0426 & 0.9112 \end{bmatrix} \right)$$

第 2 図は初期値における確率密度関数の等高線表示、第 3 図は 3 回目の繰返し後の様子をデータとともに示す。これを見ると、わずか 3 回の繰返しで、データの分布をかなりよく表す確率密度関数が生成されていることがわかる。


第 4 図の横軸は繰返し回数 p , 縦軸は不完全尤度 $L(\Theta(p))$ を表している。理論どおり、対数尤度関数は単調増加しており、特に最初の数回で尤度関数はかなり大きくなっている。

3.2 線形システムの同定


EM アルゴリズムが発表されて間もなく、Shumway と Stoffer²⁶⁾により、EM アルゴリズムを応用した線形状態空間モデルの同定方法が提案された。この場合、状態変数を欠測データとしている。モデルは



第2図 データおよび初期値における確率密度関数



第3図 3回目の繰り返し後の確率密度関数



第4図 対数尤度関数

$$x(k) = \Phi x(k-1) + w(k) \quad (29)$$

$$y(k) = M(k)x(k) + v(k) \quad (30)$$

$$w(k) \sim N(0, Q), v(k) \sim N(0, R), x_0 \sim N(\mu, \Sigma)$$

であり, w, v, x_0 は互いに独立とおく. 未知パラメータ Θ は $\Theta = \{\Phi, Q, R\}$ である. 時刻 $k=1, \dots, N$ のデータ $Y^N = \{y(1), \dots, y(N)\}$ がすでに観測されているものとして考える. いま, 状態変数もすべて既知と仮定して扱うと, 対数完全尤度関数は次のようになる.

$$\begin{aligned} \log L = & -\frac{1}{2} \log |\Sigma| - \frac{1}{2} (x_0 - \mu)^T \Sigma^{-1} (x_0 - \mu) - \frac{N}{2} \log |Q| \\ & - \frac{1}{2} \sum_{k=1}^N (x(k) - \Phi x(k-1))^T Q^{-1} (x(k) - \Phi x(k-1)) \\ & - \frac{N}{2} \log |R| \\ & - \frac{1}{2} (y(k) - M(k)x(k))^T R^{-1} (y(k) - M(k)x(k)) \end{aligned} \quad (31)$$

ここで, E, M ステップを繰り返すことになるが, 直前に得られたパラメータの推定値を $\bar{\Theta}$ と表現する.

このような動的システムの場合には条件付き期待値の条件部をその時刻のデータだけでなく常に丸ごと必要とすることに注意が必要である. 行列のトレースの性質を用いて (31) 式の括弧の中の要素を移動し, 期待値操作を施すと次式が得られる (tr はトレースを表す).

$$\begin{aligned} Q(\Theta|\bar{\Theta}) = & -\frac{1}{2} \log |\Sigma| - \frac{1}{2} tr \left[\Sigma^{-1} (P^N(0) + (x_0^N - \mu)(x_0^N - \mu)^T) \right] \\ & - \frac{N}{2} \log |Q| - \frac{1}{2} tr \left[Q^{-1} (C - B\Phi^T - \Phi B^T + \Phi A\Phi^T) \right] \\ & - \frac{N}{2} \log |R| - \frac{1}{2} tr [R^{-1} D] \end{aligned} \quad (32)$$

ここに

$$A = \sum_k (P^N(k-1) + x^N(k-1)(x^N(k-1))^T) \quad (33)$$

$$B = \sum_k (P^N(k, k-1) + x^N(k)(x^N(k-1))^T) \quad (34)$$

$$C = \sum_k (P^N(k) + x^N(k)(x^N(k))^T) \quad (35)$$

$$\begin{aligned} D = & \sum_k [(y(k) - M(k)x^N(k))(y(k) - M(k)x^N(k))^T \\ & + M(k)P^N(k)M^T(k)] \end{aligned} \quad (36)$$

であり, $x^N(k)$ はデータ $\{y(1), \dots, y(N)\}$ が得られるときの条件付き期待値 $E[x(k)|Y^N, \bar{\Theta}]$ であり, カルマンフィルタを用いた固定区間スモータ (多くの書物にアルゴリズムの記載はあるが, 例えば片山¹³⁾を参照願いたい) を用いて計算することができる. $P^N(k)$ は $E[(x(k) - x^N(k))(x(k) - x^N(k))^T | Y^N, \bar{\Theta}]$, $P^N(k, k-1)$ は $E[(x(k) - x^N(k))(x(k-1) - x^N(k-1))^T | Y^N, \bar{\Theta}]$ である.

ここでも Q, R は正定値行列であることが仮定されており, これらのいずれかが縮退するようなケースは特別にアルゴリズムを工夫しなければならないがここではこれ以上このことに深入りしない.

さて, 本問題では E ステップは $x^N(0), P^N(0)$ および $\{(x^N(k), P^N(k), P^N(k, k-1)), k=1, \dots, N\}$ を求めることである. また, M ステップは (31) 式を各パラメータで微分して 0 と置くことにより得られる尤度方程式より

$$\tilde{\Phi} = BA^{-1} \quad (37)$$

$$\tilde{Q} = \frac{1}{N} (C - BA^{-1}B^T) \quad (38)$$

$$\tilde{R} = \frac{1}{N} D \quad (39)$$

を導出できる。

状態方程式では、係数行列中のある要素は定数であることがよくある。そのような場合には、制約式を $\Phi D = \Gamma$ という形に表現することにより、制約を満たす推定式が得られることが参考文献 26) に示されているので、興味のある読者は参照されるとよい。

この問題において、欠測値がある場合、つまり $y(k)$ の一部の要素が欠けている場合についても、参考文献 26) に記述されている。まず、完全尤度 (31) 式は同じである。E ステップで、条件付き期待値を求めるときに、条件になる部分の観測値が Y^N ではなく、欠測された部分を除いた Y^{*N} となるのでデータが完全な場合とは異なる。欠測値を含む観測データからの固定区間スモージは、観測値を 0 にし、それに対応する右辺の行をすべて 0 にすることで最適なものとなることがこれも Shumway らにより示されている。観測値を 0 にするだけでは間違いであることは直感的に理解できるであろう。(32) 式第 2 項目と第 4 項目はこのようにして計算された固定区間スモージにより計算される。

第 6 項目は $E[\bar{y}(k)|Y^{*N}]$ や $E[\bar{y}(k)\bar{y}^T(k)|Y^{*N}]$ などの計算を必要とする。例えば $E[\bar{y}(k)|Y^{*N}]$ については、条件付き確率において簡単に得られる性質

$$E[\bar{y}(k)|Y^{*N}] = E[E[\bar{y}(k)|Y^{*N}, x(k)] | Y^{*N}] \quad (40)$$

に基づいて計算することができる。他も同様である。

線形動的モデルにおける欠測値は、計量経済学や生態学などで頻繁に現れる。データがないとモデリングなどで支障をきたす場合、よくその要素の単純平均などで穴埋めされるが、こうした扱いは慎重に行わなければならない。

状態空間モデルにおいて、ガウス性雑音でないノイズ成分を同定する方法として、ガウス混合密度関数を用いた同定方法²⁸⁾や、観測値における異常値を見つけながらそれを欠測値として扱いながら同定することで、異常値の悪影響を受けずに基準モデルを同定する方法²⁹⁾などを我々は提案している。

3.3 ARX モデルの同定

Isaksson¹⁰⁾は、欠測値を含む ARX モデル

$$y(k) = \sum_{j=1}^n a_j y(k-j) + \sum_{j=1}^m c_j u(k-j) + v(k) \quad (41)$$

の同定方法を開発した。とくに、出力観測値のみならず、通常は観測可能な入力値も欠測する可能性があるモデルを扱っている。これは y が自分自身の過去の値と、入力値 u のいくつかの過去の値に依存して確率的に決まる ARX モデルとなっており、入力モデルは

$$u(k) = \sum_{j=1}^n b(j)u(k-j) + w(k) \quad (42)$$

つまり、入力変数はそれ自身が過去の値に依存しながらランダムな値をとる問題となっている。これは、たとえば、環境要素が、別の要因でそれ自身が変動する入力の影響を受けて変化するような問題を表している。なお、 v と w はガウス白色雑音 $N(0, \lambda_1)$ と $N(0, \lambda_2)$ に従い、互いに無相関であると仮定する。このとき、(41) 式と (42) 式は、右辺の要素を順にならべてベクトルを定義することにより

$$y(k) = \phi_1^T(k)\theta_1 + v(k) \quad (43)$$

$$u(k) = \phi_2^T(k)\theta_2 + w(k) \quad (44)$$

と表現できる。データが $k=1, \dots, N$ までであるが、 u と y のいくつかが観測されていないものとする。このとき、それらがすべて観測されているものと仮定するときの完全尤度関数は

$$\begin{aligned} \log L(\theta, \lambda_1, \lambda_2) &= -\frac{N}{2} \log \lambda_1 - \frac{1}{2\lambda_1} \sum_{k=1}^N (y(k) - \phi_1^T(k)\theta_1)^2 \\ &\quad - \frac{N}{2} \log \lambda_2 - \frac{1}{2\lambda_2} \sum_{k=1}^N (u(k) - \phi_2^T(k)\theta_2)^2 \end{aligned} \quad (45)$$

したがって、パラメータをすべてまとめて Θ と表記すると

$$Q(\Theta|\bar{\Theta}) = E[\log L|Y^{*N}, U^{*N}, \bar{\Theta}] \quad (46)$$

ただし、 Y^{*N}, U^{*N} は $\{y(k), u(k); k=1, \dots, N\}$ のうちで観測された要素の集合を表している。

この条件付き期待値は次のようにして得られる。まず $z(k) = [y(k) \ u(k)]^T$ とおき、これを $z(k-1)$ から $z(k-n)$ まで縦に並べることにより、(43) 式、(44) 式より状態変数 $x(k)$ を定義する。観測値は $z(k)$ である。欠測値がない場合の状態空間モデルは明らかであろう。欠測値がある場合に対応させるには、欠測値がない場合単位行列、ある場合にはその部分を 0 ベクトルとおいた行列 $D(k)$ を使って、

$$z_m(k) = D(k)(H(k)x(k) + e(k)) \quad (47)$$

とおくことで得られるカルマンフィルタとそれを用いた固定区間スムーザより欠測値の条件付き期待値が求められる。

3.4 主成分分析

主成分分析法は、高次元データを、その分布の持っているパワーの大きい成分により本質的に必要な次元を求め、データを分析する方法である。簡単のために平均0と仮定した n 次元観測データを $\{y(k); k=1, \dots, N\}$ とすると、

$$y(k) = Cx(k), \quad x(k) \sim N(0_p, I_p) \quad (48)$$

となる定数行列 $C(n \times p)$ と次数 p を求める問題である。 x は隠れ変数 (latent variable) と呼ばれる未知数である。 y の共分散行列を M とすると、 M の固有値、固有ベクトルを求めることで C が求まることはよく知られている。実際、 M は半正定行列なので、正の固有値 λ_i と直交ベクトル u_i が p 組存在して

$$M = U\Lambda U^T \quad (49)$$

$$U = [u_1 | \dots | u_p], \quad \Lambda = \text{diag}(\lambda_1, \dots, \lambda_p) \quad (50)$$

と分解できる。したがって、 $C = U\Lambda^{1/2}$ とおくと、(48) 式のモデルを得る。

多くの問題で実際には観測データにはノイズが含まれると考えるのが適当である。そこで、何らかの方法で p が決定できたとして、ノイズを含めたモデルを

$$y(k) = Cx(k) + v(k) \quad (51)$$

$$x(k) \sim N(0_p, I_p), \quad v(k) \sim N(0_n, R) \quad (52)$$

とおこう。ただし v と x は互いに独立であるとする。このとき y の共分散行列は $CC^T + R$ であるので、 R が正則なら確率密度関数が求まり、確率的な扱いが可能となる。

EM アルゴリズムを使うためには完全尤度関数 $f(X^N, Y^N)$ を定め、 Y^N に基づいて完全尤度関数の期待値を求め、それを最大化するように C と R を求める。 $R = \sigma^2 I$ とおいた場合のみデータの共分散行列の固有ベクトルは、ノイズがない場合の主成分方向と一致する³¹⁾。

$$f(X^N, Y^N) = \prod_k f(y(k)|x(k))f(x(k)) \quad (53)$$

であるから、

$$f(x(k), y(k)) = \frac{\exp\left(-\frac{\|y(k) - Cx(k)\|^2}{2\sigma^2}\right)}{(2\pi\sigma^2)^{p/2}} \times \frac{\exp\left(-\frac{\|x(k)\|^2}{2}\right)}{(2\pi)^{n/2}} \quad (54)$$

となる。(53) 式の対数を取り、その Y^N の条件付き期待値をとると

$$Q(\Theta|\bar{\Theta}) = -\frac{N}{2} \log \sigma^2 - \frac{1}{2} \sum_k \text{tr} \left[\overline{x(k)x^T(k)} \right] - \frac{N}{2\sigma^2} \times \text{tr} \left[y(k)y^T(k) - 2y(k)\overline{x^T(k)}C^T + C\overline{x(k)x^T(k)}C^T \right]$$

となる。

ただし $\bar{x}$ の記号は、 $E[x|Y^N, \bar{\Theta}]$ の意味であり、ここでは

$$\overline{x(k)} = (\sigma^2 I + C^T C)^{-1} C^T y(k) \quad (55)$$

$$\overline{x(k)x^T(k)} = \sigma^2 (\sigma^2 I + C^T C)^{-1} + \overline{x(k)} \overline{x^T(k)} \quad (56)$$

である。このことは、ガウス関数となる $f(x(k)|y(k))$ の中心と共分散行列を見ることで直ちにわかる。

これより C に関して尤度方程式を解き、代入することでパラメータの更新値

$$\tilde{C} = \Sigma \bar{C} (\bar{\sigma}^2 I + (\bar{\sigma}^2 I + \bar{C}^T \bar{C})^{-1} C^T \Sigma \bar{C})^{-1} \quad (57)$$

$$\bar{\sigma}^2 = \frac{1}{p} \text{tr} \left(\Sigma - \Sigma \bar{C} (\bar{\sigma}^2 I + \bar{C}^T \bar{C})^{-1} \bar{C}^T \right) \quad (58)$$

が求まる。

なお σ^2 の値は M の $p+1$ 番目以下の固有値の平均値を表すことがわかっており³¹⁾、 p を大きく設定すると σ^2 は小さく、逆に p を小さくすると多くの情報がノイズとして扱われ、 σ^2 が大きくなるというトレードオフの関係にある。実際にはノイズを含むデータしか与えられず、正しい p はわからないということを考慮すると、 σ^2 があまり小さくならないように p を低めに設定して確率モデルを構成するのが望ましいと思われる。

3.5 ニューラルネットワーク

Jordan と Jacobs¹¹⁾ は関数近似である回帰モデルをニューラルネットワークで近似する問題において EM アルゴリズムを用いて以来、多くの研究者の注目を浴びている。これは、シグモイド関数を用いたいわゆる階層型ニューラルネットが例えば折れ曲がったような急激に性質が変わる部分を持つ関数を近似するのに向かないことから、異なる性質を持ち得る「エキスパートネット」と呼ばれるモジュールを混合する比率を決める部分を、確率的な未知変数とみなし、ここに EM アルゴリズムを適用した。モデル出力の形は

$$\mu(x) = \sum_i g_i(x) \mu_i(x) \quad (59)$$

$$\mu_i(x) = \sum_j g_{ij}(x) \mu_{ij}(x) \quad (60)$$

というように、階層的な構造をもつ。欠測値として、ガウス混合密度の場合と同様、離散型の選択変数を採用している。最下層のエキスパート出力 $\mu_{ij}(x)$ は固定された連続（非）線形関数 $f(\cdot)$ を用いた一般化線形モデル $\mu_{ij} = f(v_{ij}^T x)$ である。また、 $g_{ij}(x)$ は $(0,1)$ 区間の値をとり、 $\sum_i g_{ij}(x) = 1 (\forall x)$ であるゲーティングネットワークの値であり、それぞれ直接 x を入力とするソフトマックス関数と呼ばれる関数

$$g_{ij}(x) = \frac{\exp(v_{ij}^T x)}{\sum_j \exp(v_{ij}^T x)} \quad (61)$$

で、各層でのエキスパートの重みを与えている。このモデルでの未知パラメータを学習するにあたっては、ゲートの混合比率を確率におきかえ、各エキスパートにおいてガウス誤差項を含めることで、確率密度関数を構成し、それを元にパラメータ推定アルゴリズムを導いている。つまり、決定論的なモデルを確率モデルとして同定し、再度それを決定論的に利用するという点に大きな特徴がある。ここで、最大化すべき尤度関数は、各エキスパートにおける確率密度関数 $p(y|x, u_{ij}, \sigma^2)$ をゲーティングネットワークの値で重み付けをしては加え合わせることににより得られる最終的な混合密度関数とおいている。

EM アルゴリズムを導くにあたっては、先に述べたガウス混合モデル同様、選択変数を定義している。その結果、エキスパート内のパラメータとゲーティングパラメータは別々の最大化問題に分離され、各エキスパート内のパラメータはエキスパートごとに対数尤度関数の最大化を行う形となる。ただし、対数尤度関数は各観測値に対するそのエキスパートの事後確率で重み付けされた観測値の密度関数の和となり、極めて「常識的」な式で示されるアルゴリズムが導かれる。なお収束性については参考文献 12) に示されている。このネットワークについては、EM アルゴリズムのニューラルネットワークへの本格的な応用法として注目され、多くの解説や書物で紹介されている 9), 2), 3), 1), 24)。

ニューラルネットワークへの応用は近年急速に増えつつあり、一々述べることはできないが、ごく最近の例として、放射状関数 (radial function) を用いたネットワークによる回帰モデルへの応用が試みられた¹⁶⁾。これも非線形回帰モデルをニューラルネットを用いて実現している。ここでは、各モジュール i ごとに異なる線形モデル $\theta_i^T x$ と、放射状関数 $\phi_i(\|x - m_i\|)$ を用意し

$$y(x) = \sum_i u_i(x) \quad (62)$$

$$u_i(x) = g_i(x)(\theta_i^T x + \xi) \quad (63)$$

$$g_i(x) = \frac{\phi_i(\|x - m_i\|)}{\sum_{j=1}^n \phi_j(\|x - m_j\|)} \quad (64)$$

という形のモデルを同定している。 y は u_i の集約値となっており、EM アルゴリズムでは、 $\{u_i, i=1, \dots, n\}$ を観測値と合わせて完全データとして扱っている。 ϕ_i の中のパラメータ (m_i と広がりを表すパラメータ) は、前もってデータより推定されているものを用いるので、ここでは学習しない。 $g_i(x)$ は区間 $(0,1)$ の値をとり、任意の x に対して $\sum_i g_i(x) = 1$ となることから、線形式の混合比となっている。

4. おわりに

EM アルゴリズムの原理と、基本的な問題に対する応用方法を紙面の許す限り丁寧に記述し、読者が容易に理解できるように努めた。多くの分野でここに説明しなかった応用例が発表されている。たとえば、画像処理^{4), 15)}、強化学習⁵⁾、音声認識¹⁴⁾、信号処理^{17), 23)}、パターン認識³⁴⁾、ニューラルネットワーク^{20), 33)}、密度関数の推定^{21), 27)}、時系列解析²⁵⁾、大域的最適化³²⁾など多岐にわたり、すでに数千を数える EM アルゴリズムに関する研究は特に望まなくても頻繁に目に入るが、本記事がそれらを理解する助けになれば幸いである。

謝 辞

本記事執筆のチャンスを与えていただいた編集委員の方々に感謝します。また、数値例の計算に協力してくれた岡山大学学生の浅田昌昭君に感謝します。

(1997 年 11 月 20 日受付)

参 考 文 献

- 1) 赤穂：EM アルゴリズムの幾何学；情報処理，Vol. 37, No. 1, pp. 43-51 (1996)
- 2) S. Amari: Information geometry of the EM and em algorithms for neural networks; *Neural Networks*, Vol. 8, No. 9, pp. 1379-1408 (1995)
- 3) S. Amari: The EM algorithm and information geometry in neural network learning; *Neural Computation*, Vol. 7, No. 1, pp. 13-18 (1995)
- 4) J. Y. Chiang, Y. T. Huang and Y-L. Chang: Application of EM algorithm to image contract enhancement; *Proc. 1996 Int. Conf. on SMC*, Vol. 1, pp. 478-483 (1996)
- 5) P. Dayan and G. E. Hinton: Using expectation-maximization for reinforcement learning; *Neural Computation*, Vol. 9, pp. 271-278 (1997)

- 6) A. P. Dempster, N. M. Laird and D. B. Rubin: Maximum likelihood from incomplete data via the EM algorithm; *Journal of Royal Statistical Society*, Vol. B-39, pp. 1-38 (1977)
- 7) U. M. Fayyad, G. P. Shapiro, P. Smyth and R. Uthurusamy, Eds.: *Advances in Knowledge Discovery and Data Mining*, MIT Press (1996)
- 8) H. O. Hartley: Maximum likelihood estimation from incomplete data; *Biometrics*, Vol. 14, pp. 174-194 (1958)
- 9) S. Haykin: *Neural Networks*, Macmillan College Publishing Company (1994)
- 10) A. J. Isaksson: Identification of ARX-models subject to missing data; *IEEE Trans. on Automatic Control*, Vol. 38, No. 5, pp. 813-819 (1993)
- 11) M. I. Jordan and R. A. Jacobs: Hierarchical mixtures of experts and the EM algorithm; *Neural Computation*, Vol. 6, pp. 181-214 (1994)
- 12) M. I. Jordan and L. Xu: Convergence results for the EM approach to mixtures of experts architectures; *Neural Networks*, Vol. 8, No. 9, pp. 1409-1431 (1995)
- 13) 片山: 応用カルマンフィルタ, 朝倉書店 (1983)
- 14) Y. Konig, H. Bourlard and N. Morgan: REMAP: Recursive estimation and maximization of a posteriori probabilities - application to transition-based connectionist speech recognition; *Neural Information Processing Systems 9* (M. C. Mozer et al., Eds.), MIT Press, pp. 388-394 (1997)
- 15) R. L. Lagendijk, D. L. Angwin, H. Kaufman and J. Biemond: Recursive and iterative methods for image identification and restoration; *Signal Processing IV: Theories and Applications* (J. L. Lacoume et al., Eds.), Elsevier Science Publishers B. V. (1988)
- 16) R. Langari, L. Wang and J. Yen: Radial basis function networks, regression weights, and the expectation-maximization algorithm; *IEEE Trans. SMC-Part A*, Vol. 27, No. 5, pp. 613-623 (1997)
- 17) Shao Min and C. L. Nikias: An ML/MMSE estimation approach to blind equalization; *ICASSP'94*, Vol. 4, pp. 69-72 (1994)
- 18) 宮川: EM アルゴリズムとその周辺; 応用統計学, Vol. 16, No. 1, pp. 1-19 (1987)
- 19) T. K. Moon: The expectation-maximization algorithm; *IEEE Signal Processing Magazine*, Vol. 13, No. 6, pp. 47-60 (1996)
- 20) A. Pérez-Neira and M. A. Lagunas: Multiuse array beamforming based on a neural network mapping; *ICASSP'94*, Vol. 4, pp. 9-12 (1994)
- 21) D. Ormoneit and V. Tresp: Improved Gaussian mixture density estimates using Bayesian penalty terms and network averaging; *Advances in Neural Information Processing Systems* (D. S. Touretzky et al., Eds.), pp. 542-548, MIT Press (1996)
- 22) C. R. Rao: *Linear Statistical Inference and Its Applications*, 2nd edition, Wiley (1977) (奥野ほか訳: 統計的推測とその応用, 東京図書 (1986))
- 23) H. Sakai and T. Hayashi: Maximum likelihood parameter estimation of a sinusoid with random amplitude in white noise; *Proc. 35th CDC*, No. 3, pp. 3545-3546 (1996)
- 24) 坂和, 田中: ニューロコンピューティング入門, 森北出版 (1997)
- 25) R. H. Shumway: Some applications of the EM algorithm to analyzing incomplete time series data; *Time Series Analysis of Irregularly Observed Data* (D. Brillinger et al., Eds.), Springer-Verlag, pp. 290-324 (1984)
- 26) R. H. Shumway and D. S. Stoffer: An approach to time series smoothing and forecasting using the EM algorithm; *Journal of Time Series Analysis*, Vol. 3, No. 4, pp. 253-264 (1982)
- 27) R. L. Streit and T. E. Luginbuhl: Maximum likelihood training of probabilistic neural networks; *IEEE Trans. on Neural Networks*, Vol. 5, No. 5, pp. 764-783 (1994)
- 28) 田中, 片山: EM アルゴリズムによるスイッチングパラメータを含む線形システムの同定; システム制御情報学会論文誌, Vol. 1, No. 2, pp. 68-76 (1988)
- 29) 田中, 片山: EM アルゴリズムによる観測値に異常値を含む線形システムのロバスト同定; システム制御情報学会論文誌, Vol. 1, No. 4, pp. 117-126 (1988)
- 30) M. Tanaka: Estimation of missing elements from incomplete data by the EM algorithm; *Proc. IASTED Int. Conf. Modelling, Simulation and Optimization*, pp. 7-11 (1997)
- 31) M. E. Tipping and C. M. Bishop: Probabilistic principal component analysis, Technical Report NCRG/97/010, Dept of Computer Science & Applied Mathematics, Aston University, UK; <http://neural-server.aston.ac.uk/Papers/postscript/NCRG.97.010.ps> (1997)
- 32) 上田, 中野: 確定的アニーリング EM アルゴリズム; 電子情報通信学会論文誌 D-II, Vol. J80-D-II, No. 1, pp. 267-276 (1997)
- 33) S. Waterhouse, D. MacKay and T. Robinson: Bayesian methods for mixtures of experts; *Advances in Neural Information Processing Systems* (D. S. Touretzky et al., Eds.), pp. 351-357, MIT Press (1996)
- 34) S. R. Waterhouse and A. J. Robinson: Classification using hierarchical mixtures of experts; *Proc. IEEE Workshop on Neural Networks for Signal Processing IV*, pp. 177-186 (1994)
- 35) C. F. J. Wu: On the convergence properties of the EM algorithm; *The Annals of Statistics*, Vol. 11, No. 1, pp. 95-103 (1983)
- 36) L. Xu and M. I. Jordan: On convergence properties of the EM algorithm for Gaussian mixtures; *Neural Computation*, Vol. 8, No. 1, pp. 129-151 (1996)

著者略歴

たなか まさひろ
田中 雅博 (正会員)



1956年5月16日生。1981年3月京都大学大学院工学研究科修士課程修了。同年4月(株)島津製作所入社, 1983年5月滋賀大学経済短期大学部助手, 講師, 助教授を経て1990年岡山大学工学部情報工学科助教授となり現在に至る。現在, ニューラルネットによるパターン認識, 遺伝的アルゴリズムを使った最適化などの研究に従事。工学博士。1989年度システム制御情報学会榎本記念賞論文賞受賞。IEEE, 計測自動制御学会, 電子情報通信学会, 日本ファジィ学会, 日本シミュレーション&ゲーミング学会の各会員。